

TP3

Perceptrones

TP3 — Perceptrones
Resultados experimentales sobre cuatro problemas

Sistemas de Inteligencia Artificial · ITBA · 1Q 2026

Bloque Antes de los ejercicios

Decisiones de diseño

Decisiones que afectan a todos los ejercicios

Antes de mostrar resultados, conviene fijar los siete elementos que aparecen en cada experimento:

Decisión	Pregunta que responde
1. Función de activación	¿Qué transformación no-lineal aplicamos en cada capa?
2. Inicialización de pesos	¿Con qué valores arrancamos antes de entrenar?
3. Optimizador	¿Cómo movemos los pesos en cada paso?
4. Learning rate	¿De qué tamaño es ese paso?
5. Función de costo	¿Qué error estamos minimizando?
6. Criterio de convergencia	¿Cuándo paramos de entrenar?
7. Manejo del bias	¿Cómo lo incorporamos a cada capa?

1. Función de activación — cuál y por qué

Dónde	Cuál	Por qué
Ej 0 — AND (perceptrón)	escalón	Salida discreta $\{-1, +1\}$. Una sola capa, sin backprop, no necesita derivable.
Ej 0 — XOR (MLP)	tanh	Bipolar y derivable. Lo que pide el apunte para problemas $\{-1, +1\}$.
Ej 1 — distillation	sigmoide	Target en $[0, 1]$ (probabilidad). La sigmoide naturalmente devuelve ese rango.
Ej 2 / Ej 3 — capas ocultas	ReLU	Gradiente fuerte y constante en zona positiva. No satura como tanh/sigmoide. Entrena rápido.
Ej 2 / Ej 3 — capa de salida	softmax	Clasificación multiclase: devuelve distribución de probabilidad sobre las 10 clases.

La clase descarta dos opciones: **escalón** (no derivable) y **lineal pura** (colapsa el MLP a una transformación lineal). Las descartamos también nosotros en los MLP.

2. Inicialización de pesos — cuál y por qué

Regla del apunte: valores *pequeños, no cero, no grandes*.

- **¿Por qué no cero?** Si todas las neuronas arrancan iguales, hacen exactamente lo mismo en cada capa. El gradiente las mueve igual y *nunca se diferencian* (problema de simetría).
- **¿Por qué pequeños?** Pesos grandes saturan las activaciones (especialmente sigmoide/tanh): la salida queda en zonas planas, el gradiente es casi cero, la red no aprende.

Esquema	Distribución	Cuándo lo usamos
He	$\mathcal{N}\left(0, \sqrt{2/\text{fan_in}}\right)$	Capas con ReLU : compensa que ReLU descarta la mitad del input.
Xavier	$\mathcal{N}\left(0, \sqrt{1/\text{fan_in}}\right)$	Capas con tanh / sigmoide / softmax : mantiene varianza balanceada.
Uniforme	$\mathcal{U}[-0,1, +0,1]$	Perceptrón simple del Ej 1 (sin propagación profunda).

Modo *auto*: He para ReLU, Xavier para tanh/sigmoid/softmax, Uniform para identity. Fuente: HTML

TP3 : Perceptrones
"best weight initialization techniques" provisto por la cátedra. Nota: nuestro Xavier usa $\sqrt{1/\text{fan_in}}$
Variante (Glorot) HTML cita la forma $\sqrt{2/(\text{fan_in} + \text{fan_out})}$ empíricamente equivalente 5/49

3. Optimizador — cuál y por qué

La clase introduce **gradiente descendente clásico** (SGD); Momentum y Adam son extensiones modernas. Comparamos los tres.

- **SGD vanilla:** $w \leftarrow w - \eta \cdot \nabla L$. Lo más simple. Funciona pero es lento, especialmente en superficies con valles alargados.
- **Momentum** ($\beta = 0,9$): acumula *velocidad* en la dirección del gradiente. Atraviesa valles sin oscilar.
- **Adam** ($\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-8}$): combina momentum con *learning rate adaptativo por parámetro*. El PDF de optimizadores lo califica textual como “*muy usado en la práctica*” (defaults idénticos al paper Kingma & Ba 2015).

Resultado en Ej 2 (sweep Fase 1.2, K-fold=5):

Adam 96.74 % (best_ep=7) $\approx$ **Momentum** 96.34 % $\gg$ **SGD** 94.81 % (no convergió en 50 epochs).

Elegimos Adam por convergencia más rápida y resultado igual o mejor.

4. Learning rate — cuál y por qué

Recomendación de la clase: learning rate *pequeño*; probar varios órdenes de magnitud y mapear cómo afectan a la convergencia.

- **Demasiado grande** → la red oscila o diverge.
- **Demasiado chico** → no converge en tiempo razonable.

Experimentación en dos pasos (Ej 2):

Etapas	Valores barridos	Resultado
Fase 1.3 (k=1, coarse)	$\{10^{-4}, 5 \cdot 10^{-4}, 10^{-3}, 5 \cdot 10^{-3}, 10^{-2}\}$	10^{-3} ganó. 10^{-4} muy lento; $\geq 5 \cdot 10^{-3}$ overshooting.
Fase 2 (k=5, validación)	$\{10^{-4}, 10^{-3}, 10^{-2}, 0,1, 10\}$ con extremos	10^{-3} confirmado. 10 → accuracy random (12%). 0,1 diverge.

Elegimos $lr = 10^{-3}$ (con Adam). Validado por dos sweeps independientes y consistente con el rango típico que sugiere el apunte.

5. Función de costo — cuál y por qué

La clase arranca con MSE. Cambiar la función de costo cambia la derivada y, por lo tanto, el algoritmo de actualización.

Función	Forma	Cuándo la usamos
MSE (<i>mean squared error</i>)	$E = \frac{1}{N} \sum (y - O)^2$	Ej 0 (XOR) y Ej 1 (distillation): la salida es continua, queremos que sea cercana al target.
Cross-entropy	$E = -\frac{1}{N} \sum y \log O$	Ej 2 y Ej 3: clasificación multiclase. Penaliza fuerte la confianza en la clase incorrecta.
BCE	$E = -[y \log O + (1 - y) \log(1 - O)]$	Disponible (clasificación binaria con sigmoide). No usado en este TP.

Por qué cross-entropy + softmax en Ej 2-3: su combinación tiene un gradiente especialmente limpio, $\partial L / \partial z = O - y$, que cancela términos numéricamente delicados de la sigmoide y el logaritmo. Es la elección estándar para clasificación multiclase.

6 y 7. Convergencia y bias — decisiones de implementación

Criterio de convergencia

Ej	Criterio
Ej 1	ε absoluto sobre MSE de train (<i>regla del apunte</i> para perceptrón simple). Corta cuando $mse < \varepsilon$.
Ej 2/3	Early stopping sobre <code>val_loss</code> con <code>patience=10</code> .

Early stopping = slide 14 del PDF de regularización. Detecta overfitting que ε -train no ve.

`epochs`=50 máx; `best_epoch` promedio ~ 5 .

Manejo del bias

- **Bias trick**: agregamos columna de 1's al input de cada capa $\Rightarrow$ pesos con shape `(n_out, n_in+1)`. El bias es un peso más, se actualiza con la misma regla de gradiente.
- **El bias NO se penaliza con L2**: en Pack C, el regularizador toma `W[:,1:]` (omite la columna del bias).

Práctica estándar (Goodfellow et al. 2016, Cap. 7 — referencia citada al final del PDF de regularización): el bias no aporta varianza al modelo, penalizarlo sesga el ajuste.

Bloque 1 / 4

Validación: AND y XOR

Qué pide el TP

Tres ejercicios + una validación previa, todo evaluado experimentalmente.

Ej 0	Validación: AND con perceptrón escalón, XOR con MLP.
------	--

Ej 1	Detección de fraude por <i>knowledge distillation</i> .
------	---

Ej 2	Clasificación de dígitos manuscritos (10 clases, 28×28).
------	--

Ej 3	Mismo problema, target: accuracy $\geq 98\%$ en test .
------	--

Regla de evaluación: `digits_test.csv` se evalúa *una sola vez*, al final, con el config ganador congelado. No se toca durante búsqueda de hiperparámetros.

Ej 0 — AND con perceptrón escalón

Setup


- Representación bipolar: entradas $\{-1, +1\}$, salida esperada $[-1, -1, -1, +1]$.
- Función de activación escalón (signo).
- Regla delta clásica: $\Delta w = \eta (z - O) x$.

x_1	x_2	z esperado
-1	-1	-1
-1	+1	-1
+1	-1	-1
+1	+1	+1

Resultado: error = 0 en pocas epochs. ✓

Las cuatro muestras del AND son linealmente separables. La regla delta converge.

Ej 0 — XOR con MLP: convergencia de dos arquitecturas



El XOR no es separable linealmente. Las dos arquitecturas con capa oculta no lineal convergen. Eje y en escala logarítmica.

Ej 0 — Qué nos dice el resultado del XOR

Resultado clásico (Minsky & Papert, 1969 → Rumelhart & Hinton, 1986):

El perceptrón simple no resuelve XOR; un MLP con una capa oculta no lineal sí.

Lo que la convergencia confirma:

- **Forward pass** de la red está bien implementado.
- **Backpropagation** computa los gradientes correctos (si no, el loss no bajaría).
- Las activaciones **tanh** y sus derivadas están bien definidas.
- El loss **MSE** y su gradiente también.

Esta validación es la base para los ejercicios siguientes: la misma pipeline se reutiliza para clasificación de dígitos cambiando solo activación final (softmax) y loss (cross-entropy).

Validación completa.

El AND lo resolvió un perceptrón simple con error cero.
El XOR lo resolvieron dos arquitecturas distintas de MLP.

Siguiente: **detección de fraude**
con un perceptrón *simple* (una sola capa).

Bloque 2 / 4

Ej 1 — Knowledge Distillation

Ej 1 — El problema

Knowledge distillation: replicar la salida del BigModel pre-entrenado con un TinyModel (perceptrón simple).

Datos: `fraud_dataset.csv`

9 features (amount, session, account_age, ...)

Target de entrenamiento:

`big_model_fraud_probability` (continuo en $[0, 1]$).

Ground truth de evaluación:

`flagged_fraud` (binaria 0/1).

Regla del enunciado:

`flagged_fraud` *nunca* se usa para entrenar. Solo para métricas operativas (precision, recall, F1) post-hoc.

Salida esperada en $[0, 1]$ $\Rightarrow$
activación sigmoide.

Ej 1 — Lineal vs No-Lineal: MSE de distillation

Mismo dataset, K-fold = 5 estratificado, mismas features. Diferencia: presencia de la sigmoide.

Modelo	MSE test (mean $\pm$ std)
Lineal (Adaline)	0,0266 $\pm$ 0,0008
No-Lineal (sigmoide)	0,0110 $\pm$ 0,0004 (−59 %)

¿Por qué la sigmoide gana tan claro?

El target es una probabilidad acotada en $[0, 1]$. La sigmoide *naturalmente* mapea su salida a ese rango. El lineal puede producir valores fuera de $[0, 1]$ y el MSE penaliza fuerte esa salida fuera de dominio.

Ej 1 — El threshold default es engañoso

Modelo no-lineal con threshold = 0,5 (default obvio para sigmoide):

Precision	Recall	F1	Accuracy
0.333	1.000	0.499	0.768


Esto luce como un modelo terrible. **No es el modelo, es el threshold.**

Las salidas sigmoide se concentran en la parte alta:

- Mediana de los scores de fraude: **0.99**.
- No-fraudes *no* bajan a 0.05; bajan a 0.4–0.6.

El modelo aprendió un buen **ranking**, no una calibración perfecta. Threshold bajo
⇒ sobre-detección.


Ej 1 — Threshold sweep



Óptimo por F1: threshold = 0.89.


Precision 0,886, recall 0,861, F1 0,873, accuracy 0,971.

Ej 1 — Curvas ROC y Precision-Recall



AUC-ROC = 0.9921 (lineal: 0.9720)

TP3 · Perceptrones



PR más informativa para fraude ($\approx 12\%$
prevalencia)

Ej 1 — Recomendación de umbral

La elección depende del costo asimétrico falso positivo / falso negativo.

Threshold	Precision	Recall	F1	FP	Caso de uso
0.50 (default)	0.333	1.000	0.499	1743	—
0.89 (óptimo F1)	0.886	0.861	0.873	96	auditoría manual barata
0.95	0.949	0.746	0.835	35	FP costosos
0.99	1.000	0.527	0.690	0	cero tolerancia a FP

El modelo entrega scores. La política de threshold es decisión de negocio: auditoría manual barata $\Rightarrow$ threshold $\approx 0,89$; falsos positivos costosos $\Rightarrow$ threshold $\geq 0,95$.

Bloque 3 / 4

Ej 2 — Clasificación de dígitos

Ej 2 — El problema

Clasificación multiclase de dígitos manuscritos (0–9).

Datos:

- Train: `digits.csv` (12.449 muestras)
- Test: `digits_test.csv` (2.498)

Cada muestra: vector de 784 floats $\in [0, 1]$
(28×28 flatten).

Arquitectura final:

- Input: 784
- Hidden 1: 100 (ReLU)
- Hidden 2: 50 (ReLU)
- Output: 10 (Softmax)

Regla: el test set se evalúa una sola vez al final.
Búsqueda de hiperparámetros sólo sobre `digits.csv`.

Ej 2 — Cómo se entrena: mini-batch SGD


Tres formas de aplicar updates en gradient descent:

Modo	Update por	Trade-off
Online (SGD puro)	1 muestra	Gradiente ruidoso, lento (sin vectorizar)
Mini-batch	B muestras	Estable + rápido (matmul de NumPy)
Full-batch	todo el dataset	Estable pero costoso por update

Pseudo-código por epoch (lo que hace Ej 2 y Ej 3): **1.** shuffle del train set → **2.** partir en chunks de B muestras → **3.** para cada chunk: forward + backward + un único update.

Ej 1 (perceptrón simple) usa **online estricto** siguiendo la regla del apunte: un update por muestra. Ej 2 y Ej 3 usan **mini-batch** con B determinado por sweep (Fase 1.4).


Ej 2 — Workflow disciplinado: dos fases



Fase 1: sweeps secuenciales para reducir el espacio de búsqueda.

Fase 2: K-fold=5 para validar la elección con comparativas robustas.


Ej 2 — Sweep de Learning Rate (Fase 2)



Extremos catastróficos: $lr = 10$ deja la red en accuracy random (12 %); $lr = 0,1$ también diverge.


Óptimo: $lr = 0.001$ (consistente con la elección de Fase 1).

Ej 2 — Sweep de Arquitectura (Fase 2)



wider (200/100) gana en val por 0.17pp pero tarda $3,6\times$ más.
Empate técnico $\Rightarrow$ mantenemos la base por parsimonia.

Ej 2 — Sweep de Optimizador (Fase 2)



Adam y Momentum empatan dentro del desvío. SGD claramente atrás (y no convergió en 50 epochs sin aceleración).

⇒ Confirma la elección de Adam de Fase 1.

Ej 2 — Lo que confirmó Fase 2


Conclusión transversal de los cuatro sweeps de Fase 2:

- **Solo el sweep de LR** muestra rangos catastróficos ($lr=10$ da accuracy random, $lr=0.1$ diverge).
- **Arquitectura, optimizador, inicializador** quedan en empate técnico — ninguna alternativa supera claramente al base.

Fase 2 valida más que descubre.


La metodología coarse-to-fine de Fase 1 ya hizo el grueso del trabajo: Fase 2 confirma con $K\text{-fold}=5$ que las elecciones de Fase 1 son robustas, no suerte de un solo split.

Ej 2 — Curvas de aprendizaje del modelo base (K=5)



Convergencia limpia en ~ 5 epochs. Train y validación bajan juntos: **sin overfitting visible**.

Ej 2 — Matriz de confusión del base (val K=5)



Diagonal limpia para 9 de 10 clases. La clase 8 colapsa (precision = recall = 0). $\Rightarrow$ Hint: algo raro pasa con la distribución de los datos.

val K-fold=5: **96.22 %**




test (digits_test.csv): **86.30 %**

Drop de 10 puntos porcentuales.

Distribution shift, no underfitting. El modelo está bien — los datos no se parecen.

Ej 2 — Matriz de confusión sobre digits_test.csv



Shift, no falta de capacidad: confusiones distribuidas. $\Rightarrow$ **Más datos**, no más modelo. Eso es lo que el Ej 3 provee.

Bloque 4 / 4

Ej 3 — Pack C y conclusiones

Ej 3 — Hipótesis y plan

Hipótesis: el techo del Ej 2 es por distribution shift, no por falta de capacidad.

Plan secuencial:

1. **Más datos.** Concatenar `more_digits.csv` (15.742 muestras adicionales). Si llega a $\geq 0,98$, listo.
2. **Pack C.** Activar regularización (L2, dropout, augmentation gaussiana, lr scheduling) y combinaciones.
3. **Capacidad.** Si nada llega, probar `arch_wider`.

Cero cambios al modelo en el paso 1. Solo cambia un campo del JSON: `extra_csv_paths`.

Ej 3 — El movimiento dominó

val $K=5$: 96,22 % $\rightarrow$ 97,06 %

test: 86,30 % $\rightarrow$ 96,36 %

+10 puntos porcentuales en test.
Cero cambios al modelo. Solo más datos.

Macro F1: 0,857 $\rightarrow$ 0,959.

La clase 8 que estaba colapsada en Ej 2 ahora se predice correctamente. Más datos cubrieron el agujero de cobertura. Confirma la hipótesis del shift.

Ej 3 — ¿Qué es “Pack C”?

Nomenclatura interna del proyecto (no del enunciado): tres niveles de capacidades del engine, activados según el contexto.

Pack	Qué incluye	Cuándo lo usamos
Pack A	Perceptrón clásico (escalón, regla delta).	Ej 0 (AND) y Ej 1 (Adaline + sigmoide).
Pack B (<i>estándar académico</i>)	Activaciones, losses, optimizadores SGD/Momentum/Adam, He/Xavier, mini-batch, early stopping, K-fold.	Engine <code>mlp/</code> core. Todo Ej 2 y baseline de Ej 3.
Pack C (<i>módulos opcionales</i>)	L2, dropout, lr scheduling, augmentation gaussiana.	Solo si Ej 3 con <code>more_digits.csv</code> no alcanza $\text{target} \geq 98\%$.

¿Por qué Pack C? Para mantener la regularización avanzada *enchufable y desactivada por default*.

Ej 3 — Pack C ↔ clase de regularización

¿Qué dice el PDF de regularización y qué implementamos?

Técnica del PDF	Impl.	Resultado en Ej 3
Early stopping (slide 14)	✓	Activo en todos los configs
Augmentation — gaussiano (slide 18)	✓	$\sigma = 0,05$, +0,32 pp (parte del ganador)
Augmentation — rotaciones (slide 18)	✗	—
Augmentation — traslaciones (slide 18)	✗	—
Augmentation — cambios de escala (slide 18)	✗	—
L2 / Weight Decay (slides 20–25)	✓	$\lambda = 10^{-4}$, +0,20 pp
Dropout (slide 26 — mención)	✓	val sí, test no (−0,08 pp)
Modelos de ensamble	—	fuera de alcance
Semi-supervisado / adversarial	—	fuera de alcance


Las **tres formas de augmentation que NO implementamos** (rotaciones, traslaciones, escalas) son la hipótesis principal del techo en 96.88 % — coherente con que el shift parece geométrico, no de ruido isotrópico.

Ej 3 — Tabla de resultados Pack C

Config	val K=5	test	Δ vs base_extra
base_extra_data	0.9706	0.9636	— (referencia)
+ L2 (1e-4)	0.9758	0.9656	+0,20 pp
+ dropout (p=0.2)	0.9750	0.9628	−0,08 pp
+ L2 + dropout	0.9772	0.9604	−0,32 pp
+ L2 + aug ($\sigma = 0,05$)	0.9760	0.9688	+0,52 pp
+ L2 + aug + dropout	0.9768	0.9656	+0,20 pp
+ wider + L2 + aug	0.9777	0.9640	+0,04 pp

Ganador: L2 + augmentation gaussiana ($\sigma = 0,05$) → **96.88 % en test.**


Ej 3 — Comparación visual con Ej 2



Línea roja: target $\geq 98\%$.


El salto principal viene del baseline con extra data, no de la regularización fina.

Ej 3 — Curvas de aprendizaje del modelo ganador



Convergencia más lenta que Ej 2 base ($\text{best_ep} \sim 10$ vs 5) por la regularización L2 + augmentation. Sin overfitting visible.

Ej 3 — Matriz de confusión del ganador (test)



La clase 8 que estaba colapsada en Ej 2 ahora se predice correctamente. La diagonal está mucho más limpia, los errores residuales se reparten — síntoma de que ya no hay un agujero específico de cobertura, sino limitaciones globales del

Ej 3 — Análisis: qué movió la aguja, qué no

Lo que ayudó:

- **Más datos: +10 pp.** El movimiento dominante.
- **L2: +0,20 pp** consistente.
- **Aug gaussiana: +0,32 pp** *adicional* sobre L2 (sinergia).

Lo que no ayudó:

- **Dropout:** gana en val, pierde en test. Reduce varianza al fold, no al shift.
- **wider** [784, 200, 100, 10]: mejor en val, peor en test. Descarta falta de capacidad.
- **Combinar todo:** L2+dropout+aug peor que L2+aug solo.

Ej 3 — Por qué no llegamos al 98 %

Mejor: 96.88 %. Faltan 1.12 pp.

Tres hipótesis ordenadas por probabilidad:

1. **Augmentation insuficiente.** Gaussian noise es *isotrópico* (por píxel). El shift parece ser de *estilo de escritura*: rotación, traslación, grosor de trazo. Pide augmentation **geométrica**, no implementada acá.
2. **Sub-representación en val interno del final_eval.** Val 10 % random para early stopping puede no incluir los digits difíciles del test.
3. **Capacidad:** improbable, **wider** sobreajustó (consistente con la curva U del PDF de regularización, slide 9: más capacidad sin más datos $\Rightarrow$ overfitting).

Próximo paso: augmentation por rotación/traslación pequeñas.

Alineación con la clase — lo que seguimos del apunte

Todo el desarrollo conceptual de la clase está respetado: algoritmo, fórmulas y prácticas recomendadas.

- **Backpropagation con regla de la cadena** y δ retropropagada por capa.
- **Bias incorporado en cada capa**, como recomienda la sección de implementación.
- **Forma matricial** en toda la red, sin loops por neurona — el “tip fundamental” del docente.
- **Inicialización pequeña**, distinta según activación (He para ReLU, Xavier para tanh/sigmoid).
- **Tres optimizadores comparados**: SGD, Momentum y Adam.
- **Learning rates en varios órdenes**, incluyendo extremos que no convergen (0.1 y 10).
- **Error en función de épocas**, train y validación, en cada experimento.
- **Online en Ej 1** (regla clásica del perceptrón) y **mini-batch en Ej 2 y Ej 3**.

Alineación con la clase — decisiones distintas (y por qué)

- **No barremos online vs batch vs mini-batch** como hiperparámetro en Ej 2-3.
Mini-batch domina por costo en datasets grandes y la versión online ya está demostrada en Ej 1.
- **No barremos funciones de activación** (fijamos ReLU + softmax).
La clase descarta escalón y lineal; softmax es obligatorio en la salida multiclase; ReLU es el estándar para capas ocultas.
- **Convergencia por early stopping en validación**, no ε absoluto sobre el train.
El train solo no detecta overfitting; la validación, sí. (Ej 1 sí usa ε por su problema distinto.)
- **Implementamos `lr_schedule` (step decay), no el η adaptativo del PDF.**
El PDF muestra $\Delta\eta = +a$ si el error decrece consistente, $-b\eta$ si empieza a aumentar. Nosotros usamos step decay (`lr *= decay` cada N épocas). Misma familia (modificar η durante el entrenamiento), regla distinta.
- **La estructura del TP cambió respecto a la clase.**
La clase: Ej 1 = XOR, Ej 2 = paridad, Ej 3 = dígito + ruido. El enunciado actual (1Q 2026): Ej 1 = fraude (distillation), Ej 3 = mejorar accuracy. No es decisión nuestra.

Conclusiones del TP

Tres ideas para llevarse:

1. **Una buena pipeline gana más que tunear hiperparámetros.**
El +10pp del Ej 3 vino de *datos*, no de modelo.
2. **Los empates técnicos son más comunes que los wins claros.**
Hay que elegir por parsimonia, no por 0.05pp en val.
3. **“Mejor en val” $\neq$ “mejor en test” cuando hay shift.**
Dropout fue el ejemplo de manual: ganador en val, perdedor en test.

Item	Status
Ej 0 — step AND, MLP XOR	✓
Ej 1 — Knowledge distillation + threshold sweep	✓
Ej 2 — sweeps + final_eval + análisis del shift	✓
Ej 3 — more_digits.csv + Pack C + análisis	✓
Ej 3 — target $\geq$ 98 %	✗ (96.88 %)

Gracias.

Preguntas.
