

MÉTRICAS DEL EJ2

SIA TP3 · ITBA · Clasificación multiclase de dígitos (10 clases, 1 minoritaria)

1. LO QUE USAMOS PARA DECIDIR EN EL TP

Dos métricas en toda cell. val_acc rankea, val_loss desempata y monitorea overfitting.

val_acc — Validation Accuracy

$$\text{val_acc} = \frac{1}{N_{\text{val}}} \sum_i \mathbf{1}[\hat{y}_i = y_i]$$

Fracción de imágenes del fold val que el modelo clasifica bien.

Cálculo: forward → softmax → argmax → match. Media sobre k-folds × seeds.

► Métrica PRINCIPAL de ranking.

val_loss — Cross-Entropy en validación

$$\text{CE} = -\frac{1}{N} \sum_i \sum_c y_{i,c} \log \hat{p}_{i,c}$$

La loss que el modelo MINIMIZA al entrenar. Mide calibración de probabilidades.

Cálculo: log de la prob softmax de la clase real, promediado.

► TIE-BREAKER cuando val_acc empat. Menor CE = menos overfit.

2. MÉTRICAS DE CLASIFICACIÓN — REFERENCIA GENERAL

Las 4 fundamentales + variantes multiclase. Ancla teórica para defensa oral.

Accuracy

$$\text{acc} = \frac{TP + TN}{TP + FP + TN + FN}$$

Aciertos sobre total. Engaña con desbalance.

► Útil con clases balanceadas.

F1-score (clase c)

$$F1_c = \frac{2 P_c R_c}{P_c + R_c}$$

Media armónica de P y R .

► Castiga si P o R es bajo.

Precision (clase c)

$$P_c = \frac{TP_c}{TP_c + FP_c}$$

De lo que predije como c , ¿cuánto era c ?

► Importa si FPs son caros (spam, fraude).

Macro F1

$$\text{macroF1} = \frac{1}{C} \sum_c F1_c$$

Promedio sin pesar por frecuencia.

► Default con desbalance. ESTE TP.

Recall (clase c)

$$R_c = \frac{TP_c}{TP_c + FN_c}$$

De los c reales, ¿cuántos detecté?

► Importa si FNs son caros (cáncer).

Weighted / Micro F1

$$\text{wF1} = \sum_c \frac{n_c}{N} F1_c$$

Weighted: pesa por frecuencia. Micro: pool global (≡ acc).

► Weighted ESCONDE clases raras.

Matriz de confusión por clase c

		Realidad	
Predicción	predijo c	es c TP predijo c era c	no es c FP predijo c NO era c
	NO predijo c	FN NO predijo c era c	TN NO predijo c NO era c

TP/FP/FN/TN se cuentan por clase, después se agregan.

Regla 4 del CLAUDE.md

Reportar SIEMPRE el set completo:

- Loss de entrenamiento (CE en multiclase)
- Accuracy + Precision + Recall + F1
- Multiclase → **macro-average**

Las dos familias responden preguntas distintas:

CE → qué tan calibrada está la prob.

P/R/F1/Acc → qué tan bien clasifica argmax.