

Resumen de la sesión

Lo que hicimos

1. **Cuestionamos la elección de LR=0.001 para el no-lineal.** El informe original lo justificaba con “estabilidad numérica”, pero el plot de convergencia (mean-only) no mostraba evidencia de eso — solo que $lr=0.01$ y $lr=0.001$ convergen al mismo MSE, y 0.01 es 3x más rápido.
2. **Re-hicimos los plots con std bands** entre folds, tanto para lineal como no-lineal.
3. **Calculamos stats agregadas** (single-seed, $k=5$):
 - Lineal: $lr=0.001$ overshootea (MSE 78% peor, std 10x mayor, pesos inflados) □ confirma $lr=0.0001$ como elección correcta.
 - No-lineal: $lr=0.01$ y $lr=0.001$ indistinguibles en MSE/llw/F1. Std entre folds similar. **No hay base empírica para preferir 0.001 sobre 0.01.**
4. **Reorganizamos carpetas** en `analysis_outputs/sweep_lr/{singleseed,multiseed}` y `output/sweep_lr_singleseed/`.
5. **Escribimos** `multiseed_runner.py` + notebook Colab para correr 5 seeds × 3 LRs × 5 folds × 2 perceptrones (epochs=500). Pusheado a main.

Lo que viene

- Vos corrés el notebook en Colab y traés el ZIP.
- Eso resuelve la pregunta de “¿la dispersión entre seeds discrimina $lr=0.01$ vs $lr=0.001$ en el no-lineal?”. Si los seed-stds son comparables, queda firme que **son equivalentes** y 0.01 gana por velocidad.

Cruce con el apunte de presentación

Cosas que mi trabajo ya respalda o cambia

- **Línea 33** (“Las tres tasas... producen resultados prácticamente idénticos”) — confirmado con los nuevos números single-seed (MSE 0.01099/0.01099/0.01129; F1 0.50/0.50/0.51). Bien.
- **Línea 35** (“Hay que elegir entre 0.01 y 0.001; Podríamos decir que LR=0.001 nos...”) — quedó cortado. Mi recomendación basada en la data actual: **decí 0.01** (mismo MSE, 3x más rápido, sin penalidad medida). El multi-seed va a confirmar o no. **Evitá invocar “estabilidad numérica” sin datos que la sustenten** — fue justo el argumento que cuestionamos.
- **Línea 19** (“Justificar elección del learning rate con convergencia”) — los plots singleseed (con std) + tablas + dispersión multi-seed te dan exactamente esa justificación, ahora cuantitativa.
- **Línea 56** (“No se observa overfitting... ACA FALTA UN GRAFICO”) — los plots nuevos en `nonlinear_perceptron/analysis` ya muestran train (solid) y test (dashed) por LR; las dashed se superponen con las solid □ ese es tu gráfico de “no hay gap”. Sirve directo.
- **Línea 54** (“Perceptron lineal — Hola completame!”) — pendiente. Tengo data lista en `lineal_perceptron/analysis_outp` (tabla con MSE train/test $\approx 0.026/0.026$ □ tampoco hay gap apreciable). Falta ponerlo en formato presentación.

Cosas que NO toqué (siguen pendientes)

- Línea 8: justificación de $K=5$ por experimentación variando K — no lo hicimos.
- Línea 14: inicialización uniforme — no lo cuestionamos.
- Líneas 60-67: comparación contra baseline determinístico (precision=100% / recall=80% / acc=97.68%) y juicio de underfitting. No lo recalculamos con los modelos actuales.
- Línea 71: corrección del slide 3.